



Module 03 — Data Quality, Metadata และ Data Governance

ผู้สอน: **พศ.ดร. เอกรัฐ รัชกาญจน์**

คณะสถิติประยุกต์ · สถาบันบัณฑิตพัฒนบริหารศาสตร์ (นิด้า)

เนื้อหาใน Module นี้

1. Data Quality Framework
2. การจัดการ Metadata
3. แนวคิด Data Governance สำหรับการใช้งานข้อมูลอย่างยั่งยืน

01

Data Quality Framework

Data Quality คืออะไร

- **Data Quality** = ระดับความเหมาะสมของข้อมูลสำหรับการทำงานตามวัตถุประสงค์
- ข้อมูลที่ไม่มีคุณภาพเพียงพออาจนำไปสู่
 - การตัดสินใจที่ผิดพลาด
 - ต้นทุนในการแก้ไขข้อมูล
 - ความเชื่อมั่นในระบบข้อมูลลดลง

ผลกระทบจาก Low Data Quality

ผลกระทบ	รายละเอียด
ต้นทุน	องค์กรเสียเงิน ~15-25% ของรายได้จาก data quality issues
เวลา	Data Scientist ใช้เวลา 60-80% ในการ cleaning data
ความเชื่อมั่น	ผู้บริหารไม่เชื่อถือข้อมูล และกลับไปใช้ intuition ในการตัดสินใจ

มิติของคุณภาพข้อมูล (Dimensions)

มิติ	คำอธิบาย	ตัวอย่าง
Accuracy	ข้อมูลตรงกับความเป็นจริง	ที่อยู่ลูกค้าถูกต้อง
Completeness	ข้อมูลครบถ้วน	ไม่มี NULL ใน field ที่จำเป็น
Consistency	ข้อมูลสอดคล้องกันทั้งระบบ	สกุลเงินเดียวกันทั้งองค์กร
Timeliness	ข้อมูลเป็นปัจจุบัน	ราคาหุ้นอัปเดตเรียลไทม์
Validity	ข้อมูลตรงตามรูปแบบที่กำหนด	เบอร์โทร 10 หลัก
Uniqueness	ไม่มีข้อมูลซ้ำซ้อน	record เดียวกันไม่เกิดขึ้นซ้ำกัน
Integrity	ความสัมพันธ์ของข้อมูลถูกต้อง	Foreign key ไม่ว่างเปล่า (null)

Data Quality Framework

- **กรอบแนวทาง** สำหรับการวัด ตรวจสอบ และปรับปรุงคุณภาพข้อมูลอย่างเป็นระบบ

องค์ประกอบของ Framework

ขั้นตอน	คำอธิบาย
Assessment	ประเมินสถานะปัจจุบัน
Measurement	กำหนด KPI การวัดคุณภาพ
Monitoring	ติดตามอย่างต่อเนื่อง
Improvement	แก้ไขและป้องกันปัญหา
Governance	กำหนดบทบาทและความรับผิดชอบ

ขั้นตอนที่ 1: Assessment

- **Data Profiling** — วิเคราะห์โครงสร้างและเนื้อหาข้อมูล
 - ตรวจสอบข้อมูล, รูปแบบ, การกระจายตัว
 - หาค่า NULL, duplicate, outlier

-- ตัวอย่าง Data Profiling

SELECT

COUNT(*) AS total_rows,

SUM(CASE WHEN email IS NULL THEN 1 ELSE 0 END) AS null_email,

COUNT(DISTINCT customer_id) AS unique_customers,

MIN(order_date) AS earliest_date,

MAX(order_date) AS latest_date

FROM raw.customers;

- **Data Quality Scorecard** — ให้คะแนนแต่ละมิติ

ขั้นตอนที่ 2: Measurement

- กำหนด **Data Quality KPIs** สำหรับแต่ละมิติ

มิติ	KPI	Target
Completeness	% ของ record ที่มีค่าครบ	$\geq 99\%$
Accuracy	% ของ record ที่ตรงกับ source of truth	$\geq 98\%$
Timeliness	เวลาที่ข้อมูลถึงระบบปลายทาง	< 15 นาที
Uniqueness	% duplicate records	$< 0.1\%$
Validity	% ของ record ที่ผ่าน format validation	$\geq 99.5\%$

ตัวอย่าง: "Customer email completeness ต้องไม่ต่ำกว่า 99%"

ขั้นตอนที่ 3: Monitoring

- **Data Quality Dashboard** — แสดงสถานะคุณภาพแบบ real-time
- **Automated Data Quality Rules**

```
# ตัวอย่าง Data Quality Check (Python)

rules = ["email IS NOT NULL", "LENGTH(phone) = 10", "amount > 0", "order_date >= '2020-01-01'"]

for rule in rules:
    passed = spark.sql(f"""
        SELECT COUNT(*) as failed
        FROM sales
        WHERE NOT ({rule})
    """).collect()[0]["failed"]
    if passed > 0:
        alert(f"DQ rule failed: {rule} ({passed} rows)")
```

ขั้นตอนที่ 4: Improvement

วิธี	คำอธิบาย
Standardization	จัดรูปแบบข้อมูลให้เป็นมาตรฐานเดียวกัน
Deduplication	รวม/ลบ record ซ้ำ
Validation Rules	ตรวจสอบข้อมูลตั้งแต่จุดนำเข้า
Enrichment	เพิ่มข้อมูลจากแหล่งภายนอก
Automated Correction	แก้ไขข้อผิดพลาดอัตโนมัติ

กลยุทธ์

- **Fix at source** — แก้ที่ระบบต้นทาง
- **Fix in pipeline** — แก้ระหว่าง ETL/ELT
- **Fix at consumption** — แก้ตอนใช้งาน

Data Quality Tools

เครื่องมือ	จุดเด่น
Great Expectations	Open-source, Python-based, automated validation
Deequ	Library สำหรับ Spark (AWS Open-source)
Apache Griffin	Data quality platform สำหรับ Big Data
Soda	Open-source, CI/CD integration
dbt Tests	Built-in testing ใน dbt pipeline
Talend	Enterprise data quality platform
Informatica	Enterprise DQ suite

02

การจัดการ Metadata

Metadata คืออะไร

- **Metadata** คือ "ข้อมูลที่อธิบายข้อมูล" (Data about Data)
- ช่วยให้เข้าใจว่า **มีข้อมูลอะไร อยู่ที่ไหน หมายถึงอะไร** และ **นำไปใช้อย่างไร**

ประเภทของ Metadata

ประเภท	คำอธิบาย	ตัวอย่าง
Technical Metadata	โครงสร้างและรูปแบบของข้อมูล	Schema, data type, size, partition
Business Metadata	ความหมายทางธุรกิจ	คำจำกัดความ, business rules, data owner
Operational Metadata	การทำงานของระบบ	Job run time, error log, lineage (การ track ที่มาที่ไปของ data)
Process Metadata	ข้อมูลเกี่ยวกับขั้นตอนประมวลผล	ETL timestamp, source, transformation

ตัวอย่าง Metadata ในชีวิตประจำวัน

รูปถ่าย (Data)

└─ ขนาดไฟล์, ความละเอียด

└─ วันที่ถ่าย, GPS location

└─ ชื่อคนในรูป, คำอธิบาย

— Technical Metadata

— Process Metadata

— Business Metadata

Technical Metadata

- อธิบาย **โครงสร้างและรูปแบบ** ของข้อมูลในระดับเทคนิค

```
-- Technical Metadata (Information Schema)

SELECT  table_name,
        column_name,
        data_type,
        is_nullable,
        character_maximum_length
FROM    information_schema.columns
WHERE   table_name = 'customers';
```

ตัวอย่าง

- Table schema (column name, data type)
- Partition key, file format

Business Metadata

- อธิบาย **ความหมายทางธุรกิจ** เพื่อให้ทุกคนเข้าใจข้อมูลตรงกัน

ข้อมูล	คำอธิบาย
Customer ID	รหัสประจำตัวลูกค้า ระบบ CRM
Customer Tier	ระดับลูกค้า เช่น Bronze/Silver/Gold/Platinum
CLV	Customer Lifetime Value — คำนวณจากยอดซื้อ 12 เดือนล่าสุด
Churn Flag	ลูกค้าที่ไม่มีการซื้อเกิน 90 วัน

ประโยชน์

- ลดความสับสนในการตีความข้อมูล
- ทำให้ Data Catalog มีประโยชน์
- สร้าง common vocabulary ในองค์กร

Operational Metadata

- อธิบาย **การทำงาน** ของระบบข้อมูล

ข้อมูล	คำอธิบาย
Pipeline Run ID	ระบุการทำงานแต่ละครั้ง
Start / End Time	เวลาที่ job เริ่มและจบ
Rows Processed	จำนวน record ที่ประมวลผล
Status	Success / Failed / Running
Error Log	รายละเอียดข้อผิดพลาด

ประโยชน์

- Troubleshooting pipeline
- Performance monitoring and Data lineage tracking

Data Catalog


- ศูนย์รวม metadata ของทั้งองค์กร
- ทำให้ ค้นหา เข้าใจ และเข้าถึง ข้อมูลได้

ความสามารถหลัก

ความสามารถ	คำอธิบาย
Search & Discovery	ค้นหาข้อมูลจากคำค้นหา
Data Profiling	แสดงสถิติและคุณภาพข้อมูล
Data Lineage	แสดงที่มาและการเปลี่ยนแปลงของข้อมูล
Data Dictionary	คำจำกัดความของ data element
Access Control	จัดการสิทธิ์การเข้าถึง

Data Lineage

- **แสดงเส้นทางของข้อมูล** ตั้งแต่ต้นทางไปยังปลายทาง
- เข้าใจว่าข้อมูล **มาจากไหน ผ่านการแปลงอะไร ไปใช้ที่ไหนบ้าง**



ประโยชน์

- Impact analysis — ถ้าเปลี่ยน schema source ส่งผลถึง dashboard ไหน?
- Root cause analysis — data ผิด เกิดจากขั้นตอนไหน?
- Compliance — ตรวจสอบแหล่งที่มาของข้อมูล

Metadata Management Tools

เครื่องมือ	ลักษณะ	จุดเด่น
Apache Atlas	Open-source	Governance และ lineage สำหรับ Hadoop
DataHub	Open-source (LinkedIn)	Modern, real-time metadata
Amundsen	Open-source (Lyft)	Data discovery และ search
Alation	Commercial	Enterprise data catalog
Collibra	Commercial	Data governance และ catalog
dbt Docs	Lightweight	Auto-generated docs จาก dbt model
Atlantis	Open-source (Airbnb)	Data discovery

03

แนวคิด Data Governance สำหรับการใช้งาน ข้อมูลอย่างยั่งยืน

Data Governance คืออะไร

- **กรอบแนวทางและกระบวนการ** ในการจัดการข้อมูลให้มีคุณภาพ ปลอดภัย และใช้ประโยชน์ได้สูงสุด
- **ครอบคลุม: นโยบาย มาตรฐาน บทบาทหน้าที่ และ กระบวนการ** ที่เกี่ยวข้องกับข้อมูล


เป้าหมายหลัก

- **Data Quality** — ข้อมูลถูกต้อง น่าเชื่อถือ
- **Data Security** — ป้องกันการเข้าถึงโดยไม่ได้รับอนุญาต
- **Data Compliance** — ปฏิบัติตามกฎหมาย (PDPA, GDPR)
- **Data Value** — ใช้ข้อมูลสร้างมูลค่าให้องค์กร
- **Data Democratization** — ผู้เกี่ยวข้องเข้าถึงข้อมูลได้

หลักการสำคัญของ Data Governance

Data Governance Principles	
Accountability	กำหนดเจ้าของข้อมูล
Transparency	การใช้ข้อมูลโปร่งใส
Integrity	ข้อมูลถูกต้องเชื่อถือได้
Security	ข้อมูลปลอดภัย
Compliance	ปฏิบัติตามกฎระเบียบ
Standardization	มาตรฐานเดียวกัน
Sustainability	ใช้ข้อมูลอย่างยั่งยืน

Data Governance Framework



บทบาทหน้าที่ (Roles & Responsibilities)

บทบาท	ใคร	หน้าที่
Data Owner	หัวหน้าฝ่ายธุรกิจ	รับผิดชอบข้อมูล, กำหนด access policy
Data Steward	ผู้เชี่ยวชาญข้อมูล	ดูแล data quality, business glossary
Data Custodian	IT / Data Engineer	จัดการ infrastructure, security
Data Governance Council	ผู้บริหารระดับสูง	กำหนดนโยบาย, อนุมัติมาตรฐาน
Data Consumer	ผู้ใช้ข้อมูล	ใช้งานข้อมูลตาม policy

Data Owner ตอบโจทย์ "ใครรับผิดชอบข้อมูลนี้?"

Data Steward ตอบโจทย์ "ใครดูแลคุณภาพข้อมูล?"

Data Stewardship

- **Data Steward** = ผู้ดูแลข้อมูลประจำวัน เป็น bridge ระหว่าง business และ technical teams

หน้าที่หลัก

- **Define business glossary** — กำหนดคำศัพท์ทางธุรกิจ
- **Set data quality rules** — กำหนดกฎคุณภาพข้อมูล
- **Resolve data issues** — แก้ปัญหาข้อมูล
- **Document lineage** — บันทึกที่มาของข้อมูล
- **Train users** — อบรมการใช้งานข้อมูล

ประเภทของ Data Steward

- **Business Steward** — focus ที่ business meaning
- **Technical Steward** — focus ที่ data system
- **Domain Steward** — focus ที่ domain-specific data

Data Policy & Compliance

นโยบายหลักที่องค์กรควรมี

นโยบาย	คำอธิบาย
Data Classification Policy	ระดับความลับของข้อมูล (Public/Internal/Confidential/Restricted)
Data Access Policy	ใครเข้าถึงข้อมูลอะไรได้บ้าง
Data Retention Policy	เก็บข้อมูลเท่าไร? ลบเมื่อไหร่
Data Privacy Policy	การจัดการข้อมูลส่วนบุคคล (PDPA/GDPR)
Data Sharing Policy	การแบ่งปันข้อมูลภายใน/ภายนอก
Data Quality Policy	มาตรฐานคุณภาพข้อมูล

Data Classification

ระดับ	คำอธิบาย	ตัวอย่าง
Public	เปิดเผยต่อสาธารณะได้	ราคาสินค้า, ที่อยู่สาขา
Internal	ใช้ภายในองค์กร	รายงานยอดขายรายเดือน
Confidential	เฉพาะผู้มีสิทธิ	ข้อมูลเงินเดือน, strategy plan
Restricted	เฉพาะบุคคลที่จำเป็น	ข้อมูลลูกค้า, รหัสผ่าน

การควบคุมตามระดับความลับ

- Public → ไม่มีข้อจำกัด
- Internal → ต้องมี authentication
- Confidential → ต้องมี authorization + encryption
- Restricted → ต้องมี approval + audit log

Data Governance Tools

เครื่องมือ	ลักษณะ	จุดเด่น
Collibra	Commercial	Data governance + catalog + lineage
Alation	Commercial	Data catalog + governance + ML
Apache Atlas	Open-source	Governance + lineage สำหรับ Hadoop
DataHub	Open-source	Metadata platform + governance
Okera	Commercial	Data access control + audit
Privacera	Commercial	Data security + compliance
Unity Catalog	Databricks	Governance สำหรับ Lakehouse

Data Governance Maturity Model

ระดับ	ลักษณะ
Level 1 — Initial	ไม่มี governance ชัดเจน, ต่างคนต่างทำ
Level 2 — Reactive	มี governance เฉพาะบางส่วน, แก้ปัญหาเฉพาะหน้า
Level 3 — Proactive	มีนโยบายและกระบวนการ, มี data steward
Level 4 — Managed	Governance เป็นส่วนหนึ่งของกระบวนการ, มี KPI
Level 5 — Optimized	Governance เป็นวัฒนธรรมองค์กร, ปรับปรุงต่อเนื่อง

เป้าหมาย: ยกระดับจาก **Reactive** → **Proactive** → **Managed**

แนวทางการเริ่มต้น Data Governance

1. **Start small** — เลือกข้อมูลที่สำคัญที่สุด (Critical Data Elements)
2. **Identify stakeholders** — หา Data Owner และ Data Steward
3. **Define metrics** — วัดผลสำเร็จ (Data Quality Score, Compliance Rate)
4. **Build tools** — เลือกเครื่องมือที่เหมาะสม
5. **Communicate** — สื่อสารให้ทั่วองค์กร
6. **Iterate** — ปรับปรุงอย่างต่อเนื่อง

ข้อควรระวัง

- อย่าพยายามทำทุกอย่างพร้อมกัน
- อย่าสร้าง governance ที่ซับซ้อนเกินไป
- ต้องมี executive support
- ต้อง focus ที่ business value ไม่ใช่แค่ compliance

สรุป Module 03

หัวข้อ	Key Takeaways
Data Quality Framework	5 ขั้นตอน: Assessment → Measurement → Monitoring → Improvement → Governance
การจัดการ Metadata	Technical / Business / Operational Metadata, Data Catalog, Data Lineage
Data Governance	Roles (Owner/Steward/Custodian), Policy, Compliance, Maturity Model

หัวใจสำคัญ: Data Quality + Metadata + Governance = รากฐานของข้อมูลที่ยั่งยืน

คำถาม?

Questions & Discussion

ผศ.ดร. เอกรัฐ รัชกาญจน์

ekarat@as.nida.ac.th

ekaratnida.github.io

คณะสถิติประยุกต์ · สถาบันบัณฑิตพัฒนบริหารศาสตร์ (นิด้า)